Module BDR
Master d'Informatique (SAR)

Cours 9- bases de données parallèles

Stéphane Gançarski
Stephane.Gancarski@lip6.fr

Plan

Introduction

Architectures

Placement des données

Parallélisme dans les requêtes

Optimisation de requêtes

Introduction

- Les machines parallèles deviennent courantes et abordables
  - Les prix des microprocesseurs, de la mémoire et des disques ont fortement diminué
- Les BD sont de plus en plus volumineuses (ex. entrepôts de données, multimedia, …)
- Principe des BD parallèles :
  - utiliser les machines parallèles (systèmes distribués) pour exploiter le parallélisme dans la gestion de données.

Parallélisme dans les BD

- Les données peuvent être partitionnées sur plusieurs disques pour faire des entrées/sorties en parallèle.
- Les opérations relationnelles (tri, jointure, agrégations) peuvent être exécutées en parallèle
  - Les données peuvent être partitionnées, et chaque processeur peut travailler indépendamment sur sa partition
- Les requêtes sont exprimées dans un langage de haut niveau (SQL), et traduites en opérateurs algébriques.
  - Facilite le parallélisme
- Les requêtes peuvent être exécutées en parallèle

Objectifs des BD parallèles

- Améliorer les performances
- Améliorer la disponibilité
- Réduire les coûts (utiliser plusieurs petites machines est moins cher qu'un gros ordinateur).

- Les SGBD parallèles sont utilisés pour :
  - Stocker de très grandes quantités de données
  - Effectuer des requêtes d'aide à la décision coûteuses
  - Permettre le traitement de transactions à haut débit

5

Architectures de BD parallèles

- Se classent selon ce qui est partagé :
  - Shared Memory Systems (partage de la mémoire)
  - Shared Disk Systems (partage du disque)
  - Shared Nothing Systems (pas de partage)
  - Hybrid Systems (systèmes hybrides)

6

Mémoire partagée

- Tous les processeurs partagent le disque et la mémoire

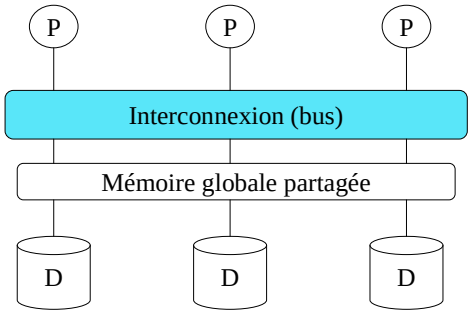

7

Mémoire partagée

+ simplicité
+ équilibrage de charge
+ parallélisme inter-requête (ajout de processeur)
- Peu extensible : limité à une dizaine de processeurs
- Cher : chaque processeur est lié à chaque module de mémoire
- Conflits d'accès à la mémoire (dégrade les performances)
- Pb de disponibilité des données en cas de défaut de mémoire

Utilisé dans plusieurs systèmes commerciaux : Oracle, DB2, Ingres

8

Disques partagés

- Ensemble de noeuds (processeurs et mémoire) ayant accès via un réseau d'interconnexion à tous les disques (les mémoires ne sont pas partagées).

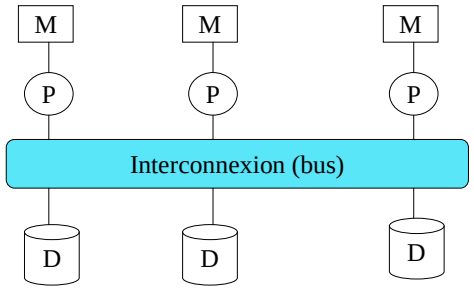

9

Disques partagés

+ moins cher que les systèmes à mémoire partagée.
+ extensibilité (centaines de processeurs) : les processeurs ont suffisamment de mémoire cache pour minimiser les interférences sur le disque.
+ bonne disponibilité (les défauts de mémoire sont locaux à un processeur)
+ migration facile de systèmes existants (pas de réorganisation des données sur le disque)
- Assez complexe
- Pbs de performance :
  - Verrous distribués pour éviter les accès conflictuels aux mêmes pages,
  - maintien de la cohérence des copies,
  - l'accès aux disques partagés peut devenir un goulot d'étranglement
- Utilisé dans IMS/VS(IBM), VAX (DEC)

10

Aucun partage

- Les différents noeuds sont reliés par un réseau d'interconnexion. Chaque processeur a un accès exclusif à la mémoire et au disque (idem BD réparties).

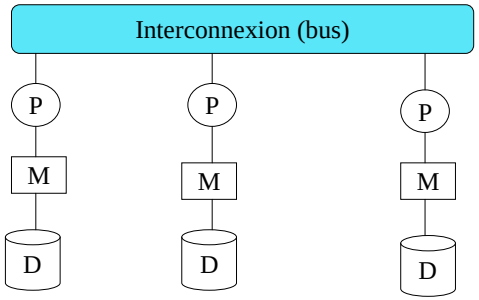

11

Aucun partage

+ Coût semblable à celui des disques partagés
+ Bonne extensibilité (milliers de noeuds)
+ Disponibilité par réplication des données

Bien adapté au parallélisme intra-requête

- Plus complexe que les systèmes à mémoire partagée (mêmes fct. qu'en BD réparties)
- Répartition de charge difficile à mettre en oeuvre, à cause de la répartition statique des données
- Ajouter des noeuds entraîne une réorganisation des données (pour permettre la répartition de charge)
- Utilisé dans ICL Goldrush, Teradata DBC, EDS, …

12

Systèmes hybrides

- Combinaison de systèmes à mémoire partagée et de systèmes sans partage.

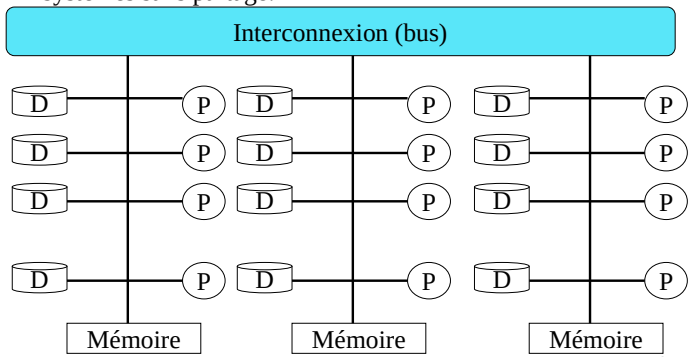

13

Systèmes hybrides

- Chaque noeud individuel est un système à mémoire partagée.

+ Combine la souplesse et les performances des systèmes à mémoire partagée avec les capacités d'extensibilité des systèmes sans partage.

+ La communication au sein de chaque noeud est efficace (mémoire partagée).

+ Bon compromis entre répartition de charge et passage à l'échelle.

14

Partitionnement des données

- Répartir les données sur les disques permet de réduire le temps d'accès aux données.
- Partitionnement horizontal : les n-uplets d'une relation sont répartis sur les différents disques (pas de partitionnement de n-uplet).
- Différentes techniques de partitionnement (nb de disques = n) :
  - **Round-robin** : le $i^{ème}$ n-uplet inséré dans la relation est stocké sur le disque *i mod n*
  - **Partitionnement par hachage (hash partitioning) :**
    - Choisir un ou plusieurs attributs comme attributs de partitionnement
    - Appliquer une fonction de hachage (renvoyant un entier de 0 à n-1) à ces attributs
    - Stocker le n-uplet sur le disque correspondant au résultat de la fonction de hachage

15

Partitionnement des données (suite)

- **Partitionnement par intervalles (range partitionning)** : répartit les n-uplets en fonction des intervalles de valeurs d'un attribut
  - Choisir un attribut pour le partitionnement
  - Choisir un vecteur de partitionnement $[v_0, v_1, \ldots, v_{n-2}]$
  - Soit v la valeur de l'attribut de partitionnement.
    - Les n-uplets tq $v<v_0$ vont sur le disque 0
    - Les n-uplets tq $v \geq v_{n-2}$ vont sur le disque n-1
    - Les n-uplets tq $v_i < v \leq v_{i+1}$ vont sur le disque i+1

16

Comparaison

- Comparer sur les opérations :
  - Parcours de la relation (scan)
  - Sélection sur égalité (ex: R.A=15)
  - Sélection sur intervalles (ex: $10 \leq R.A < 25$)
- **Round-robin** :
  - Convient bien au parcours de relations
  - Bonne répartition des n-uplets sur les disques (bonne répartition de charge)
  - Mal adapté aux requêtes avec sélection (pas de regroupement, les données sont dispersées)

17

Comparaison (suite)

Partitionnement par hachage

- Efficace pour les accès séquentiels
  - Si on a une bonne fonction de hachage, et si le(s) attribut(s) de partitionnement est (sont) clé, il y a bonne répartition des n-uplets sur les disques, et une bonne répartition de la charge pour rechercher les données
- Efficace pour les sélections par égalité sur l'attribut de partitionnement
  - La recherche peut se limiter à un seul disque
  - Possibilité d'avoir un index local sur l'attribut de partitionnement
- Mal adapté aux sélections sur intervalles, car il n'y a pas de regroupement.

18

Comparaison (suite)

Partitionnement par intervalle

- Les données sont regroupées par valeurs de l'attribut de partitionnement
- Efficace pour les accès séquentiels
- Efficace pour les sélections par égalité sur l'attribut de partitionnement
- Bien adapté aux sélections sur intervalles (seul un nombre limité de disques est concerné)
  - Efficace si les n-uplets du résultat se trouvent sur peu de disques
- Risque de répartition inégale sur les disques

19

Partitionnement d'une relation

- Ne pas partitionner une relation qui tient sur un seul disque
- Utiliser l'ensemble des disques pour un partitionnement
- Ne pas partitionner plus que nécessaire : si une relation tient sur *m* blocs et qu'il y a *n* disques, partitionner sur *min(n,m)* disques

20

Gestion des répartitions non uniformes

- Certains algorithmes de répartition risquent de donner lieu à une répartition inégale des données (bcp sur un disque, peu sur un autre), ce qui peut dégrader les performances:
  - Mauvais choix de vecteur de partition
  - Mauvais choix de fonction de hachage
  - Répartition inégale des valeurs d'un attribut de partitionnement
- Solutions (partitionnement par intervalles) :
  - Créer un vecteur de partitionnement équilibré (trier la relation sur l'attribut de partitionnement et diviser en sous-ensembles de même taille)
  - Utiliser des histogrammes

Parallélisme inter-requêtes

- Forme la plus simple du parallélisme
- Les requêtes (et les transactions) s'exécutent en parallèle
- Augmente le débit de transactions (utilisé pour augmenter le nombre de transactions par seconde)
- Plus difficile à implémenter sur les architectures disque partagé et sans partage
  - La coordination des verrouillages et des journaux s'effectue par envois de messages entre processeurs
  - Les données d'un buffer local peuvent avoir été mises à jour sur un autre processeur
  - Nécessité de maintenir la cohérence des caches (les lectures et écritures dans le buffer doivent concerner la version la plus récente.)

Cohérence du cache

- Protocole pour les architectures à disques partagés :
  - Avant de lire/écrire une page, la verrouiller en mode partagé/exclusif
  - Une page verrouillée doit être lue du disque
  - Avant de déverrouiller une page, elle doit être écrite sur le disque (si elle a été modifiée)
- Des protocoles plus complexes existent, limitant les lectures/écritures sur disque.
- Des protocoles semblables existent pour les architectures sans partage.

Parallélisme intra-requêtes

- Exécuter une seule requête en parallèle sur plusieurs processeurs (important pour les requêtes longues)
- Deux formes de parallélisme :
  - **Inter-opérateurs** : exécuter plusieurs opérations en parallèle
  - **Intra-opérateurs** : paralléliser l'exécution de chaque opération dans la requête

Parallélisme inter-opérateurs

- Deux formes :
  - **Pipeline** : plusieurs opérateurs sont exécutés en parallèle, le résultat intermédiaire n'est pas matérialisé. Gain de place mémoire et minimise les accès disque
  - **Parallélisme indépendant** : les opérateurs sont indépendants, pas d'interférence entre les processeurs. Le résultat est matérialisé.

Parallélisme intra-opérateurs

- Décomposer un opérateur en un ensemble de sous-opérateurs, chacun s'exécutant sur une partition de la relation.

  Exemple pour la sélection :

  $\sigma\ (R) \equiv \sigma_{S1}\ (R_1)\ \sigma_{S2}(R_2)\ \ldots\ \sigma_n(R_n)$
- Pour les jointures, on utilise les propriétés du partitionnement : par ex. si R et S sont partitionnées par hachage sur l'attribut de jointure, et s'il s'agit d'une équi-jointure, on peut partitionner la jointure en deux jointures indépendantes.

Traitement parallèle des opérateurs relationnels

- Suppositions :
  - Requêtes en lecture seule
  - Architecture sans partage
  - N processeurs, et N disques (D_1 est associé à P_1)
- Les architectures sans partage peuvent être simulées efficacement sur des architectures à mémoire partagées ou à disques partagés. Les algorithmes peuvent être appliqués, avec différentes optimisations, sur ces architectures.

Tri parallèle

Range-partitioning sort :

- Choisir les processeurs P_0,… P_m, avec m<n, pour faire le tri.
- Créer des vecteurs de partition par intervalle avec m entrées, sur l'attribut de jointure
- Redistribuer la relation selon cette partition :
  - tous les n-uplets du $i_{ème}$ intervalle sont envoyés au processeur P_i
  - P_i stocke temporairement les n-uplets sur son disque D_i
- Chaque processeur trie sa partition de la relation localement (en parallèle, sans interaction avec les autres processeurs)
- On fusionne les différents résultats.

Tri parallèle

Trifusion parallèle externe :

- La relation est partitionnée sur les n disques.
- Chaque processeur trie localement ses données.
- La fusion est parallélisée :
  - Les partitions triées sur chaque processeur sont partitionnées par intervalle sur les différents processeurs (utiliser le même vecteur de partition)
  - Chaque processeur fusionne les données qu'il reçoit à la volée.
  - Les différents résultats sont concaténés

Jointures parallèles

- Principes :
  - La jointure consiste à tester les n-uplets deux par deux et à comparer la valeur des attributs de jointure.
  - Le parallélisme consiste à répartir ces tests sur des processeurs différents, chacun calculant une partie de la jointure localement.
  - Les résultats sont ensuite rassemblés.

Jointure par partitionnement

- Partitionner les deux relations (par hachage ou par intervalle) en n partitions, sur l'attribut de jointure, en utilisant la même fonction de hachage ou le même vecteur de partitionnement.
- Les partitions r_i et s_i sont envoyées au processeur P_i.
- Chaque processeur calcule la jointure entre r_i et s_i (avec n'importe quel algorithme)
- Les résultats sont concaténés.

Jointure par partionnement

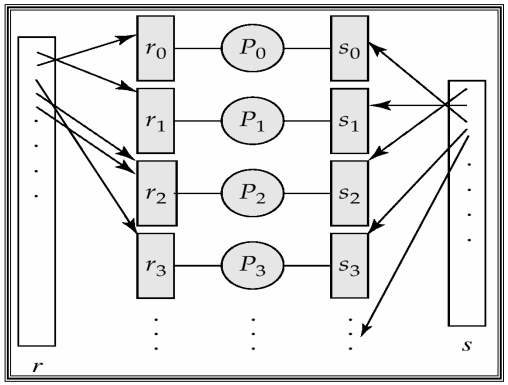

Boucles imbriquées en parallèle

- Les relations R et S sont fragmentées en m et n fragments respectivement.
- Envoyer les m fragments de R sur les n nœuds où se trouvent des fragments de S.(en parallèle)
- Faire la jointure sur ces nœuds.(en parallèle)
- Concaténer les résultats.

33

Jointure parallèle par hachage

- Partitionner (en parallèle) les relations R et S en k partitions à l'aide d'une fonction de hachage h appliquée à l'attribut de jointure tq

$$R \infty S = U_{(i=1..k)} (Ri \infty Si)$$

- Les partitions de R et de S ayant même valeur de hachage sont envoyées sur le même processeur.
- Faire les jointures sur chaque processeur en parallèle
- Concaténer les résultats

34

Jointure parallèle par hachage

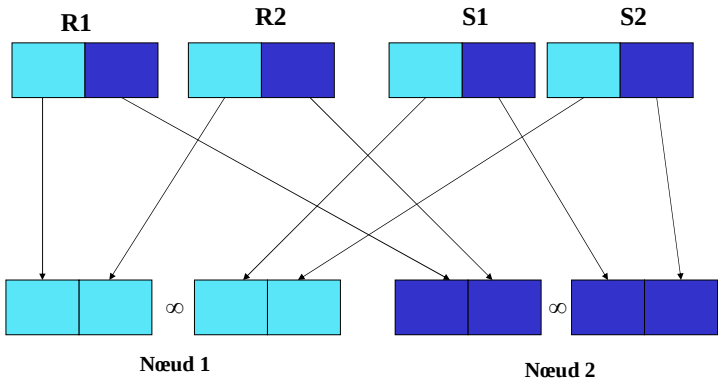

35

Optimisation de requêtes

- Semblable à l'optimisation de requêtes dans les BD réparties.
- Espace de recherche
  - Les arbres algébriques sont annotés pour permettre de déterminer les opérations pouvant être exécutées à la volée (pipeline). Génération d'arbres en profondeur gauche, droite, en zig-zag, touffus.
- Modèle de coût
  - Dépend en partie de l'architecture
- Stratégie de recherche
  - Les mêmes qu'en environnement centralisé (les stratégies aléatoires sont mieux adaptées en raison de la taille de l'espace de recherche)

36

Conclusion

- Les BD parallèles améliorent
  - Les performances,
  - La disponibilité
  - L'extensibilité

Tout en réduisant le ratio prix/performance.

Plusieurs systèmes commercialisés.

Pbs :

choisir la meilleure architecture

améliorer les techniques de placement de données (éviter les répartitions inégales)

37